

AVALIAÇÃO COMPUTADORIZADA DE SACROILIÍTE EM IMAGENS DE RESSONÂNCIA MAGNÉTICA

Matheus Calil Faleiros¹, José Raniery Ferreira Junior², Vitor Faeda Dalto³, Marcello Henrique Nogueira-Barbosa³, Paulo Mazzoncini de Azevedo-Marques³

¹Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto (FFCLRP) e Faculdade de Medicina de Ribeirão Preto (FMRP) da Universidade de São Paulo (USP).

²Escola de Engenharia de São Carlos (EESC), Faculdade de Medicina de Ribeirão Preto (FMRP) e Instituto de Química de São Carlos (IQSC) da Universidade de São Paulo (USP).

³Faculdade de Medicina de Ribeirão Preto (FMRP) da Universidade de São Paulo (USP).

Resumo: Objetivos: avaliar e classificar a atividade inflamatória nas articulações sacroilíacas de pacientes com espondiloartrite em imagens de ressonância magnética, utilizando atributos de textura e de histograma de níveis de cinza. Métodos: imagens de 51 pacientes foram avaliadas retrospectivamente e segmentadas manualmente por um radiologista. Trinta e nove atributos de brilho e de textura foram utilizados para caracterizar a presença ou ausência de processo inflamatório. A classificação foi realizada utilizando-se diferentes classificadores e avaliada por um método de validação cruzada com 10-fold. Resultados: uma rede neural multicamadas, utilizando o conjunto total de atributos, alcançou o melhor desempenho no estudo, obtendo 0,915 de área sob a curva ROC, 0,864 de sensibilidade e 0,724 de especificidade. Conclusões: o processamento computadorizado implementado possui bom potencial como base para o desenvolvimento de uma ferramenta de auxílio ao diagnóstico de processo inflamatório de articulações sacroilíacas de pacientes com espondiloartrites.

Palavras-chave: Processamento de Imagem Assistida por Computador; Inflamação; Reumatologia.

Abstract: Goals: to evaluate and classify the inflammatory process in sacroiliac joints of patients with spondyloarthritis in magnetic resonance imaging using attributes of texture and gray-level histogram. Methods: images from 51 patients were retrospectively evaluated and manually segmented by a radiologist. Thirty nine attributes of histogram and texture were used to characterize the presence or absence of the inflammatory process. Classification was performed by several classifiers and evaluated with a 10-fold cross-validation. Results: a multilayer neural network and all extracted attributes obtained highest diagnostic performance in the study with 0.915 of area under the ROC curve, 0.864 of sensitivity and 0.724 of specificity. Conclusions: the implemented computerized processing presents good potential as a starting point for the development of a tool to aid the diagnosis of inflammatory process of sacroiliac joints of patients with spondyloarthritis.

Keywords: Computer-Assisted Image Processing; Inflammation; Rheumatology.

Introdução

As espondiloartrites (EpA) são um grupo de doenças inflamatórias crônicas com alta prevalência e que apresentam características clínicas e radiológicas comuns. As EpA acometem predominantemente jovens, com início médio dos sintomas aos 31 anos com forte potencial de morbidade e impacto socioeconômico, causando comprometimento de coluna vertebral, esqueleto apendicular e em especial das articulações sacroilíacas. A avaliação e monitoramento das espondiloartrites apresenta dificuldade na prática diária, em decorrência da variabilidade de apresentações clínicas².

Os exames de imagem apresentam fundamental importância na avaliação desses pacientes, sendo a ressonância magnética (RM) o método mais sensível para diagnóstico precoce. A RM é capaz de

detectar edema ósseo nas articulações sacroilíacas (Figura 1), sendo esse achado um dos critérios diagnósticos mais importantes dos protocolos clínicos atuais³. Porém, a avaliação radiológica visual desarmada das articulações sacroilíacas ainda pode apresentar desafios aos especialistas, além de possíveis variações intra- e inter-pessoal na interpretação das imagens. Para uniformizar a descrição dos achados, avaliações semi-quantitativas, como a proposta pela iniciativa SPARCC4 (Spondyloarthritis Research Consortium of Canada), foram estabelecidas. Porém, elas ainda apresentam significativa variabilidade interobservador e grau elevado de complexidade para uso na rotina clínica.




Figura 1 - Exemplos de imagens de ressonância magnética apresentando articulações sacroilíacas (elipse azul) normal (Figura (a)) e com inflamação (Figura (b)). Pode-se observar o aumento do sinal (maior brilho) ao redor das superfícies articulares das articulações sacroilíacas apresentadas na Figura (b) em relação à Figura (a).

Nesse contexto, o objetivo do trabalho aqui apresentado foi estabelecer um procedimento de classificação computadorizada das articulações sacroilíacas, baseado em atributos quantitativos extraídos de imagens de RM, com o objetivo de auxiliar o diagnóstico das EpA. Segundo nosso conhecimento, até o presente momento não encontramos na literatura trabalhos que classifiquem as articulações em positivas e negativas para inflamação de forma semi-automática, conforme aqui apresentado.

O restante do artigo está organizado como segue: na Seção Métodos, são apresentados os métodos utilizados no desenvolvimento do trabalho, como a aquisição e pré-processamento das imagens de RM, a segmentação das articulações sacroilíacas, a extração dos atributos quantitativos das imagens e os classificadores utilizados. Na Seção Resultados, os resultados obtidos são apresentados e avaliados. Na seção Discussão. Por fim, o artigo é concluído na Seção 4 e os agradecimentos e referências apresentados nas Seções 5 e 6, respectivamente.

Métodos

Aquisição, Pré-processamento e Segmentação das Imagens – Foram utilizadas imagens de 51 pacientes, sendo que 22 destes casos foram classificados como positivos para sacroiliíte e os demais 29 negativos, de acordo com os critérios diagnósticos para RM do ASAS5 (Assessment of SpondyloArthritis international Society). As imagens foram obtidas em aparelho de 1.5T (Achieva, Philips

Medical Systems) usando a bobina de coluna, com os pacientes em decúbito dorsal. A sequência obtida para análise foi coronal ponderada em T2 com saturação de gordura (SPAIR) com seguintes parâmetros técnicos: TE: 60ms, TR: range 1500-3000ms, espessura de corte de 4mm e matriz de 148 x 127, totalizando um tempo de aquisição de 3:28min para cada paciente. Foram utilizados seis cortes consecutivos dessas sequências para cada paciente.

Um radiologista especialista em sistema musculoesquelético realizou a segmentação manual das articulações sacroilíacas (Figura 2). Foram identificadas e marcadas com um quadrilátero as articulações esquerda e direita de cada paciente. As regiões contendo as articulações foram inseridas em um fundo preto. O processo de segmentação manual foi realizado com a ferramenta Adobe Photoshop CC.




Figura 2 – Processo de segmentação manual das articulações sacroilíacas.

Extração de Atributos das Imagens – O processo de extração de atributos foi realizado nas 6 imagens de RM segmentadas para cada paciente. Trinta e nove atributos foram extraídos de cada imagem, sendo 7 relativos ao histograma de níveis de cinza e 32 de textura. Cada paciente foi caracterizado por um vetor de atributos de 234 dimensões (6 imagens x 39 atributos). Dos 32 atributos de textura, 14 foram propostos por Haralick et al.⁶ e 18 por Tamura et al.⁷

O histograma de nível de cinza representa a frequência de ocorrência de cada nível de cinza dentro da imagem estudada. Os atributos extraídos dos histogramas de níveis de cinza utilizados neste trabalho foram:

$$\text{Média } (\mu) = \sum_i^n \sum_j^m \frac{P(i,j)}{m \times n} \quad (1)$$

$$\text{Desvio Padrão } (dp) = \sqrt{\frac{\sum (P(i,j) - \mu)^2}{(m \times n) - 1}} \quad (2)$$

$$\text{Assimetria} = \frac{N}{(N-1)(N-2)} \sum \left(\frac{P(i,j) - \mu}{dp} \right)^3, \quad (3)$$

$$\text{Kurtosis} = \left[\frac{N(N+1)}{(N-1)(N-2)(N-3)} \sum \left(\frac{P(i,j) - \mu}{dp} \right)^4 \right] - \frac{3(N-1)^2}{(N-2)(N-3)} \quad (4)$$

$$\text{Variância} = dp^2,$$

$$\text{Coeficiente de Desvio} = \frac{dp}{\mu} \quad (5)$$

$$\text{Máximo} = \text{Max}[P(i,j)] \quad (6)$$

onde m e n se referem, respectivamente, ao número de linhas e número de colunas da imagem $P(i,j)$ é o nível de cinza do *pixel* no ponto (i,j) .

Os atributos de textura de Haralick foram calculados a partir da matriz de coocorrência de níveis de cinza das imagens segmentadas. A matriz de coocorrência representa a probabilidade de ocorrência de pares de *pixels* da imagem. Os atributos de textura que foram utilizados no trabalho e calculados a partir da matriz de coocorrência foram:

$$\text{Segundo momento angular} = \sum_{i,j} P^2(i,j) \quad (6)$$

$$\text{Contraste} = \sum_{i,j} |i - j|^2 P(i,j) \quad (7)$$

$$\text{Correlação} = \sum_{i,j} \frac{(ij)P(i,j) - \mu_x \mu_y}{\sigma_x \sigma_y} \quad (8)$$

$$\text{Variância}(v) = \sum_{i,j} (i - \mu)^2 P(i,j) \quad (9)$$

$$\text{Momento da diferença inversa} = \sum_{i,j} \frac{1}{1 + (i-j)^2} P(i,j) \quad (10)$$

$$\text{Média da soma} = \sum_i i P_{x+y}(i), \quad (11)$$

$$\text{Entropia da soma (es)} = - \sum_i P_{x+y}(i) \log(P_{x+y}(i)) \quad (12)$$

$$\text{Variância da soma} = \sum_i (i - es)^2 P_{x+y}(i) \quad (13)$$

$$\text{Entropia (e)} = - \sum_{i,j} P(i,j) \log(P(i,j)) \quad (14)$$

$$\text{Variância da diferença} = v(P_{(x-y)}) \quad (15)$$

$$\text{Entropia da diferença} = \sum_i P_{x-y}(i) \log(P_{x-y}(i)) \quad (16)$$

$$\text{MIC 1} = \frac{- \sum_{i,j} P(i,j) \log P(i,j) + \sum_{i,j} P(i,j) \log(P_x(i) P_y(j))}{\max\{e_x, e_y\}} \quad (17)$$

$$\text{MIC2} = (1 - \exp^{-2 \sum_{i,j} P(i,j) \log P(i,j) + \sum_{i,j} P(i,j) \log(P_x(i) P_y(j))})^{1/2} \quad (18)$$

$$\text{Coeficiente de correlação máxima} = \sum_{i,j} \frac{P(i,k) P(j,k)}{P_x(i) P_y(k)}^{1/2} \quad (19)$$

em que MIC é a medida de informação de correlação, $P(i,j)$ é o elemento na matriz de coocorrência, μ_x, μ_y são as médias, σ_x, σ_y são os desvios padrões, x, y são as dimensões da imagem e i, j é o par de nível de cinza.

Segundo Tamura, Mori e Yamawaki⁷, os atributos de Tamura correspondem a percepção visual humana e fornecem uma descrição da textura da imagem diferente da proposta por Haralick et al. As características de Tamura utilizadas no trabalho foram contraste, granularidade e direcionalidade, sendo esta última subdividida em 16 atributos, de acordo com as equações abaixo:

$$\text{Contraste} = \sum_n n^2 (\sum_{i,j} P(i,j)) \quad (20)$$

$$\text{Granularidade} = \frac{1}{m \times n} \sum_i^m \sum_j^n S_{best}(i,j) \quad (21)$$

$$\text{Direccionalidade} = H_d(k) = \frac{N_o(k)}{\sum_{i=0}^{n-1} N_o(i)} \quad (22)$$

onde $P(i,j)$ é a (i,j) -tésima entrada da matriz de níveis de cinza, m e n em Granularidade são as dimensões da imagens e $S_{best}(i,j)$ é o maior tamanho de vizinhança que dê o maior valor de saída na diferença média de pares opostos e em Direccionalidade $N_o(k)$ é o numero de pontos em $(2k-1)\pi/2n \leq \theta \leq (2k+1)/2n$ e $n = 16$. Todos os atributos foram extraídos pela biblioteca JFeatureLib⁸, baseada no projeto Lucene Image Retrieval (LIRE)⁹, com a linguagem de programação Java.

Classificação das Imagens e Avaliação Diagnóstica – Para realizar a classificação dos exames, foram utilizados métodos clássicos de aprendizado de máquina: *k-nearest neighbors* (KNN), *naive bayes* (NB), *multilayer perceptron* (MLP), árvore de decisão J48 e *random forest* (RF). Os classificadores estão implementados na ferramenta *open source* de mineração de dados Weka¹⁰ e podem ser descritos como se segue:

KNN: também conhecido como algoritmo de aprendizado baseado em instância, o KNN escolhe a classe predominante entre os k vizinhos mais próximos para classificar uma instância de teste com classe desconhecida. O valor de k usado nos experimentos variou de 1 a 5;

NB: classificador probabilístico baseado no teorema de Bayes;

MLP: rede neural multicamadas, onde cada camada é um classificador linear. O MLP utilizou uma taxa de aprendizado de 0,3 e termo de momento de 0,2;

J48: árvore de decisão que seleciona os atributos mais descritivos para classificação. O J48 é a implementação em Java da árvore de decisão C4,5 e utilizou fator de confiança 0,25;

RF: constrói uma floresta de árvores de decisão geradas aleatoriamente. Nos experimentos, o RF utilizou 100 árvores e 8 atributos aleatoriamente.

A classificação foi realizada com uma validação cruzada estratificada 10-*fold* pelo software Weka. A precisão diagnóstica dos classificadores foi avaliada pela área sob a curva ROC (AUC - *area under the ROC curve*), sensibilidade e especificidade. Sensibilidade é a proporção de casos positivos para inflamação corretamente classificados, e especificidade é a proporção de casos negativos para inflamação corretamente classificados, de acordo com as equações:

$$\text{Sensibilidade} = \frac{VP}{VP+FN} \quad (23)$$

$$\text{Especificidade} = \frac{VN}{VN+FP} \quad (24)$$

em que VP, VN, FP e FN são os valores verdadeiro-positivos, verdadeiro-negativos, falso-positivos e falso-negativos, respectivamente.

Resultados

As Tabelas 1, 2 e 3 apresentam a AUC, sensibilidade e especificidade, respectivamente, obtidas nos experimentos para os diferentes classificadores e categorias de atributos extraídos das imagens de RM. O classificador KNN é apresentado pelo valor atribuído a k .

Tabela 1. AUC apresentada como mapa de calor e obtida por diferentes classificadores e categorias de atributos de imagens.

	Atributos				Média ± Desvio Padrão	AUC
	Histograma	Haralick	Tamura	Todos		
Classificadores						
k = 1	0.755	0.663	0.605	0.725	0.687 ± 0.067	0.58
k = 2	0.713	0.715	0.676	0.727	0.708 ± 0.022	0.60
k = 3	0.839	0.712	0.670	0.759	0.745 ± 0.072	0.65
k = 4	0.862	0.672	0.678	0.703	0.729 ± 0.090	0.70
k = 5	0.832	0.655	0.640	0.755	0.721 ± 0.090	0.75
NB	0.793	0.775	0.793	0.809	0.793 ± 0.014	0.80
MLP	0.697	0.710	0.871	0.915	0.798 ± 0.111	0.85
J48	0.772	0.710	0.580	0.681	0.686 ± 0.080	0.90
RF	0.812	0.704	0.763	0.783	0.766 ± 0.046	0.92
Média ± Desvio Padrão	0.786 ± 0.057	0.702 ± 0.036	0.697 ± 0.094	0.762 ± 0.070		

Tabela 2. Sensibilidade apresentada como mapa de calor e obtida por diferentes classificadores e categorias de atributos de imagens.

	Atributos				Média ± Desvio Padrão	Sensibilidade
	Histograma	Haralick	Tamura	Todos		
Classificadores						
k = 1	0.773	0.636	0.636	0.682	0.682 ± 0.065	0.25
k = 2	0.500	0.873	0.409	0.364	0.387 ± 0.094	0.25
k = 3	0.727	0.636	0.682	0.591	0.659 ± 0.059	0.43
k = 4	0.636	0.409	0.500	0.455	0.500 ± 0.098	0.51
k = 5	0.773	0.636	0.636	0.682	0.682 ± 0.065	0.59
NB	0.727	0.682	0.682	0.773	0.716 ± 0.044	0.67
MLP	0.682	0.682	0.818	0.864	0.761 ± 0.094	0.75
J48	0.727	0.500	0.682	0.636	0.636 ± 0.098	0.80
RF	0.636	0.545	0.545	0.500	0.557 ± 0.057	0.86
Média ± Desvio Padrão	0.687 ± 0.086	0.555 ± 0.140	0.621 ± 0.120	0.616 ± 0.158		

Tabela 3. Especificidade apresentada como mapa de calor e obtida por diferentes classificadores e categorias de atributos de imagens.

		Atributos				Média ± Desvio Padrão	Especificidade
		Histograma	Haralick	Tamura	Todos		
Classificadores	k = 1	0.759	0.690	0.517	0.724	0.673 ± 0.107	0.48
	k = 2	0.828	0.862	0.828	0.862	0.845 ± 0.020	0.54
	k = 3	0.724	0.759	0.586	0.724	0.698 ± 0.077	0.60
	k = 4	0.966	0.828	0.828	0.828	0.863 ± 0.069	0.66
	k = 5	0.690	0.655	0.586	0.690	0.655 ± 0.049	0.72
	NB	0.793	0.724	0.724	0.828	0.767 ± 0.052	0.78
	MLP	0.690	0.724	0.828	0.724	0.741 ± 0.060	0.84
	J48	0.793	0.793	0.483	0.724	0.698 ± 0.147	0.90
	RF	0.793	0.793	0.793	0.828	0.802 ± 0.017	0.97
Média ± Desvio Padrão		0.782 ± 0.085	0.759 ± 0.067	0.686 ± 0.143	0.770 ± 0.065		

De acordo com os Tabelas de 1 a 3, os 3 cenários que apresentaram melhor desempenho para auxílio ao diagnóstico foram MLP com todos os atributos combinados (0,915 de AUC, 0,864 de sensibilidade e 0,724 de especificidade), MLP com os atributos de Tamura (0,871 de AUC, 0,818 de sensibilidade e 0,828 de especificidade) e KNN com k igual a 4 e atributos de histograma (0,862 de AUC, 0,636 de sensibilidade e 0,966 de especificidade).

Discussão

Embora a MLP tenha apresentado resultados um pouco superiores, não foi verificada diferença estatisticamente significativa entre estes cenários (nível de confiança de 95%). As Figuras 3 e 4 apresentam as curvas ROC e os intervalos de confiança de sensibilidade e especificidade destes 3 cenários, respectivamente.




Figura 3 - Curvas ROC dos cenários que apresentaram maior performance diagnóstica.

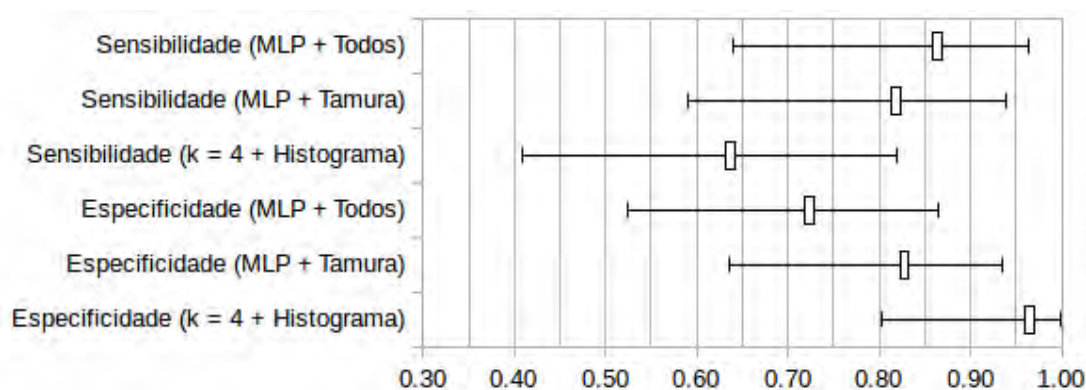


Figura 4 - Intervalos de confiança de sensibilidade e especificidade dos cenários que apresentaram melhor desempenho na tarefa diagnóstica.

Como observado nas Tabelas 1, 2 e 3, os atributos de histograma obtiveram maior estabilidade entre os classificadores, com AUC ($0,786 \pm 0,057$), sensibilidade ($0,687 \pm 0,086$) e especificidade ($0,782 \pm 0,085$), com médias superiores aos outros atributos. Além disso, o vetor de atributos de histograma representa apenas 18% do vetor completo com todos os atributos combinados, o que gera uma redução do custo computacional no processo de extração de características.

Entre os classificadores, a rede neural MLP obteve a maior performance diagnóstica com AUC e sensibilidade médias de $0,798 \pm 0,111$ e $0,761 \pm 0,094$, respectivamente. A maior especificidade foi obtida pelo KNN ($k = 4$) e valor médio de $0,863 \pm 0,069$.

Apesar da classificação com MLP e todos os atributos combinados ter obtido a maior performance diagnóstica entre todos os cenários, ela apresentou alto custo computacional para treinar o modelo de classificação dos casos (uma média de 12 segundos por *fold* e 2 minutos em uma validação cruzada 10-*fold*). Em contrapartida, a classificação com KNN ($k = 4$) e atributos de histograma apresentou

performance diagnóstica estatisticamente equivalente ao cenário descrito anteriormente (Figura 4) e baixo custo computacional, visto que o KNN não faz uso de um modelo de treinamento de casos (apenas realiza a busca pelos vizinhos próximos) e o vetor de atributos é constituído por apenas 18% do total do espaço de características. Contudo, se o número de amostras a ser comparado pelo KNN for grande, o classificador levará mais tempo para definir a classe de um caso desconhecido e o custo computacional será maior do que o de uma rede neural MLP.

Conclusão

Este trabalho propôs um método para classificação de atividade inflamatória de articulações sacroilíacas em imagens de ressonância magnética. Foram avaliados atributos de histograma, textura de Haralick e de Tamura para a caracterização das articulações e métodos de aprendizado de máquina para a classificação dos casos. Os resultados obtidos indicam que o processamento computadorizado implementado possui bom potencial como base para o desenvolvimento de uma ferramenta de auxílio ao diagnóstico de processo inflamatório de articulações sacroilíacas de pacientes com espondiloartrites.

O trabalho, porém apresenta algumas limitações, como por exemplo, o processo de segmentação das imagens, que demanda tempo do especialista. Com o intuito de superar essa limitação, propomos para trabalhos futuros a segmentação automática das articulações sacroilíacas e a validação clínica da classificação computadorizada como ferramenta de auxílio ao diagnóstico da sacroiliite inflamatória.

Agradecimentos

Agradecemos ao Prof. Dr. Paulo Louzada Junior e ao Dr. Rodrigo Luppino Assad pelo uso dos pacientes do ambulatório de reumatologia do Departamento de Clínica Médica da Faculdade de Medicina de Ribeirão Preto (FMRP) da Universidade de São Paulo (USP). Agradecemos também as instituições Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP), Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq), Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES) e Fundação de Apoio ao Ensino, Pesquisa e Assistência (FAEPA) do Hospital das Clínicas da Faculdade de Medicina de Ribeirão Preto (HCFMRP) da Universidade de São Paulo (USP), pelo apoio financeiro ao estudo.

Referências

- [1] Sampaio-Barros P. Epidemiology of Spondyloarthritis in Brazil. *The American Journal of the Medical Sciences*. 2011;341(4):287-288.
- [2] Pialat J, Di Marco L, Feydy A, Peyron C, Porta B, Himpens P, Ltaief-Boudrigua A, Aubry S. Sacroiliac joints imaging in axial spondyloarthritis. *Diagnostic and Interventional Imaging*. 2016.
- [3] Rudwaleit M, Jurik A, Hermann K, Landewe R, van der Heijde D, Baraliakos X, Marzo-Ortega H, Ostergaard M, Braun J, Sieper J. Defining active sacroiliitis on magnetic resonance imaging (MRI) for classification of axial spondyloarthritis: a consensual approach by the ASAS/OMERACT MRI group. *Annals of the Rheumatic Diseases*. 2009;68(10):1520-1527.
- [4] Maksymowych W, Inman R, Salonen D, Dhillon S, Williams M, Stone M, Conner-spady B, Palsat J, Lambert R. Spondyloarthritis research Consortium of Canada magnetic resonance imaging index for assessment of sacroiliac joint inflammation in ankylosing spondylitis. *Arthritis Rheum*. 2005;53(5):703-709.

- [5] Rudwaleit M, van der Heijde D, Landewe R, Listing J, Akkoc N, Brandt J, Braun J, Chou C, Collantes-Estevez E, Dougados M, Huang F, Gu J, Khan M, Kirazli Y, Maksymowych W, Mielants H, Sorensen I, Ozgocmen S, Roussou E, Valle-Onate R, Weber U, Wei J, Sieper J. The development of Assessment of SpondyloArthritis international Society classification criteria for axial spondyloarthritis (part II): validation and final selection. *Annals of the Rheumatic Diseases*. 2009;68(6):777-783.
- [6] Haralick R, Shanmugam K, Dinstein I. Textural Features for Image Classification. *IEEE Transactions on Systems, Man, and Cybernetics*. 1973;3(6):610-621.
- [7] Tamura H, Mori S, Yamawaki T. Textural Features Corresponding to Visual Perception. *IEEE Transactions on Systems, Man, and Cybernetics*. 1978;8(6):460-473.
- JFeatureLib open source project. Disponível em: <https://github.com/locked-fg/JFeatureLib> Último acesso em 02/05/2016. Fontes: Haralick.java - Autor: graf; Tamura.java - Autor: Marko Keuschnig & Christian Penz; Histogram.java - Autor: graf;
- [8] Lux M, Chatzichristofis S. LIRE: Lucene Image Retrieval – An Extensible Java CBIR Library. In *proceedings of the 16th ACM International Conference on Multimedia*, pp. 1085-1088, Vancouver, Canada, 2008.
- [9] Hall M, Frank E, Holmes G, Pfahringer B, Reutemann P, Witten I. The WEKA data mining software. *SIGKDD Explor Newsl*. 2009;11(1):10.

Contato

Paulo Mazzoncini de Azevedo-Marques
Av. dos Bandeirantes 3900, Campus USP -
Monte Alegre
14049-900, Ribeirão Preto, São Paulo, Brasil
Tel: + 55 16 36022647 FAX:+ 55 16 36022648
E-mail: pmarques@fmrp.usp.br